

Sumário

1	Introdução	2
2	Material e Método	2
2.1	Base de dados	2
2.1.1	Pré-processamento	2
2.2	Algoritmos de treinamento	3
2.2.1	Divisão de dados	3
2.2.2	Amostragem estratificada	3
2.2.3	Normalização dos atributos	3
2.3	Crerios de avaliaão	3
3	Análise experimental	4
3.1	Resultados	4
3.1.1	Modelo 1	4
3.1.2	Modelo 2	4
3.2	Comparação algorítmica	5
4	Conclusão	5
5	Apêndice	5

1 Introdução

Nesse trabalho foram desenvolvidos dois modelos de classificação usando o algoritmo de árvore de decisão com o propósito de atuar como uma triagem inicial para casos de suspeitas de arboviroses. Os modelos foram treinados usando planilhas de dados disponibilizados pelo DataSUS (portal do SUS que compila notificações do Sinan)¹ sobre casos de suspeita de dengue e chikungunya. O primeiro modelo foi treinado para, dado um novo paciente, classificar ele como tendo ou não arbovirose. O segundo modelo foi treinado para, dado um paciente com arbovirose, essa arbovirose é classificada como dengue ou chikungunya.

2 Material e Método

2.1 Base de dados

A base de dados da dengue contém planilhas divididas por ano, que vão desde 2000 até 2026. Os dados sobre chikungunya seguem a mesma divisão por ano, porém com intervalo de tempo menor, de 2015 à 2026. Para o treinamento não foram utilizados todos os anos, somente um intervalo entre 2021 e 2025, essa escolha se deve por 2021 ter sido o ano da última mudança na estruturação das planilhas, a partir desse ano todas as planilhas seguem a mesma estrutura facilitando o trabalho de pré-processamento.

Para diminuir qualquer viés que algum ano onde houve algum surto de arbovirose poderia adicionar, foi montado um dataset de amostras das 5 planilhas de cada arbovirose. Foram retirados 20 mil amostras aleatórias de cada ano, totalizando 100 mil amostras de suspeita de dengue e 100 mil amostras de suspeita de chikungunya. Assim, o dataset que será pré-processado consiste em 122 atributos e 200.000 instâncias.

2.1.1 Pré-processamento

O primeiro passo do pré-processamento foi uma análise semântica de cada atributo, removendo atributos para diminuir a dimensionalidade do modelo. Entre os atributos removimos há variáveis de controle do próprio sistema de notificação, redundâncias, atributos demográficos irrelevantes para o modelo, como grau de escolaridade; além de atributos referentes ao prognóstico e resultados de exames para evitar vazamento de dados.

A exclusão difere na tratativa das comorbidades: as comorbidades foram mantidas no modelo 2. Na literatura médica, o histórico prévio pode influenciar na manifestação diferenciada entre Dengue e Chikungunya, sendo útil para a distinção entre os vírus.

¹<https://dadosabertos.saude.gov.br/dataset/arboviroses-dengue>
<https://dadosabertos.saude.gov.br/dataset/arboviroses-febre-de-chikungunya>

Após a diminuição da dimensionalidade:

- Modelo 1: um dataset com 45 atributos e 200.000 instâncias.
- Modelo 2: um dataset com 52 atributos e 200.000 instâncias.

No segundo passo foram feitas uma engenharia de atributos e regras de negócio. Foram mapeadas as variáveis alvo:

- Modelo 1: 'Descartado' vira 0 e qualquer Confirmado vira 1.
- Modelo 2: Dengue vira 0 e Chikungunya vira 1.

Além disso, a idade original foi convertida para anos inteiros, os dias para notificação foram calculados, os sinais de alarme e gravidade foram condensadas em duas novas features booleanas e o sexo e os sintomas foram binarizados.

2.2 Algoritmos de treinamento

2.2.1 Divisão de dados

A divisão de dados foi feita na proporção de 80% do dataset para treino e 20% para teste, servindo como o simulador do cenário real de triagem e diagnóstico no posto de saúde.

2.2.2 Amostragem estratificada

Devido ao desbalanceamento de classes observado nas notificações do SINAN, a divisão entre treino e teste é feita de forma estratificada. Isso garante que a proporção exata de casos positivos e negativos/descartados seja preservada idêntica tanto no conjunto de treino quanto no de teste, evitando que o modelo seja avaliado em um cenário irreal.

2.2.3 Normalização dos atributos

Algoritmos baseados em cálculo de distância geométrica, como o KNN, são altamente sensíveis à escala dos dados. Se não houver tratamento, um atributo contínuo dominaria completamente o cálculo da distância Euclidiana em relação a uma variável binarizada. Para mitigar isso, foi aplicado o StandardScaler, que centraliza os dados na média zero e escala a variância para a unidade.

2.3 Critérios de avaliação

Os critérios de avaliação utilizados foram:

- Acurácia: mede a fração global de previsões corretas do modelo, independentemente da classe.
- Precisão Macro: mede a proporção de instâncias classificadas como positivas que são verdadeiramente positivas e negativas que são verdadeiramente negativas.
- Recall: mede a capacidade do modelo de identificar todas as instâncias reais pertencentes a uma determinada classe.
- F1-Score Macro: mede a média harmônica entre a sua Precisão e o seu Recall.
- Desvio padrão: mede a dispersão das acurácias durante a validação cruzada.

3 Análise experimental

3.1 Resultados

3.1.1 Modelo 1

O modelo de triagem falhou em capturar a nuance clínica do diagnóstico. Devido ao severo desbalanceamento de classes e à ausência de atributos como sintomas respiratórios na ficha de notificação, a Árvore de Decisão baseou seu aprendizado no atributo temporal devido à sazonalidade das arboviroses. O modelo atua de forma enviesada, assumindo que quadros febris no período de epidemia são sempre positivos, o que prejudicou drasticamente sua capacidade de identificar verdadeiros negativos. Critérios de avaliação:

- Acurácia: 0,73
- F1-Score Macro: 0,50
- Precisão Macro: 0,64

3.1.2 Modelo 2

Ao focar na diferenciação entre dois vírus já confirmados, o Modelo 2 apresentou resultados bons e clinicamente interpretáveis. A Árvore de Decisão elegeu de forma autônoma a ausência/presença de artralgia como nó raiz, validando matematicamente o consenso da literatura médica de que dores articulares intensas são o principal divisor clínico entre Dengue e Chikungunya. Critérios de avaliação:

- Acurácia: 0,80
- F1-Score Macro: 0,78
- Precisão Macro: 0,79

3.2 Comparação algorítmica

Tanto a Árvore de Decisão quanto o KNN lidaram bem com a não-linearidade do problema, apresentando métricas de acurácia e F1-Score semelhantes. No entanto, a Árvore de Decisão demonstra ser uma escolha técnica superior para este contexto. O ganho não se dá apenas pela métrica bruta, mas pela sua interpretabilidade. Foi a estrutura de regras da árvore que permitiu auditar o modelo, diagnosticar o viés temporal do Modelo 1 e confirmar o rigor biomédico do Modelo 2.

4 Conclusão

O trabalho cumpriu o objetivo de estruturar e aplicar técnicas de Aprendizado Supervisionado em uma base de dados governamental complexa e ruidosa (SINAN). A análise experimental dos modelos evidencia que, no contexto de dados de saúde pública, a qualidade da engenharia de atributos e a compreensão clínica do problema são tão determinantes quanto a escolha do algoritmo.

Próximos passos para a evolução do experimento do Modelo 1:

- Excluir a variável `mes_sintomas` para forçar os algoritmos a procurarem padrões estritamente clínicos.
- Aplicar técnicas de reamostragem para estabilizar o Recall.
- Procurar datasets onde há a inclusão de sintomas mais característicos de gripes, como sintomas respiratórios por exemplo. Isso forneceria as características excludentes necessárias para diferenciar quadros gripais comuns de suspeitas reais de arboviroses.

Colab: <https://colab.research.google.com/drive/1axUa3oWJbKUiRUY3kROB...usp=sharing>

5 Apêndice

Como a Árvore de Decisão sacrificou o Recall da classe minoritária (Descartados), para observar se é possível forçar o algoritmo a aprender os padrões dessa classe sem depender de novos atributos excludentes, foi aplicada a técnica de Oversampling SMOTE (Synthetic Minority Over-sampling Technique).

Como resultado, o Recall da classe minoritária subiu, mas a Acurácia e o F1-Score geral caíram. Portanto, sem atributos excludentes, não há fronteira matemática que separe as classes. O modelo precisa de novas features, não apenas de mais dados.